

Практическое задание 4

Рыбка Елизавета, 474




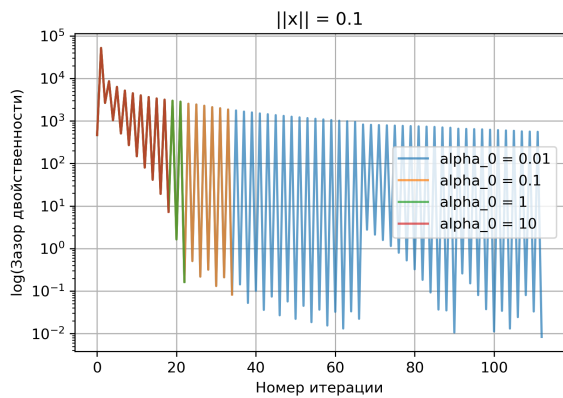
19 декабря 2017 г.

Эксперимент 1: Выбор длины шага в субградиентном методе

Генерируем данные:

- Матрица A размера $m \times n$ с помощью функции `np.random.rand` т.е. каждый элемент матрицы случайным образом выбран из нормального распределения на $[0, 1)$.
 $n = 1000, m = 100$
- b — нулевой вектор $\in \mathbb{R}^m$
- $x_0 \in \mathbb{R}^n$ также создается с помощью `np.random.rand`. Затем производится нормировка $x_0 = d \frac{x_0}{\|x_0\|}$. Т.е. в итоге получается вектор сонаправленный исходно сгенерированному, но длины d

Приведем графики зависимости работы субградиентного метода в зависимости от константы α_0 для различных начальных точек. Т.к b — нулевой вектор x^* находится около нуля. Поэтому $\|x_0\|$ можно считать расстоянием от начальной точки до искомой. $\lambda = 0.5$



Выводы:

Построенные графики полупрозрачны, поэтому из однородности последнего ($\|x_0\| = 10$) делаем вывод, что метод работает одинаково для всех протестированных α_0 при данном $x_0, \|x_0\|$. В целом из графиков можно сделать вывод, что лучше работает большое α_0 , но до тех пор пока оно больше $\|x_0\|$. При пересечении же этой границы разницы нет. Почему?? Т.к. в реальной жизни мы не знаем насколько далеко наша начальная точка находится от искомой, то по большому счету этот анализ нам ничего не дает.

Эксперимент 2: Среднее число итераций линейного поиска в схеме Нестерова

Генерируем данные:

- Матрица A размера $m \times n$ с помощью функции `np.random.rand` т.е. каждый элемент матрицы случайным образом выбран из нормального распределения на $[0, 1)$. $n = 1000, m = 1000$
- $b \in \mathbb{R}^m$ создается с помощью `np.random.rand`
- $x_0 \in \mathbb{R}^n$ — нулевой вектор

Представим результаты на графиках:




Рис. 1: Зависимость суммарного числа итераций линейного поиска от числа итераций простого метода. Полный график (слева) и приближенный график (справа)




Рис. 2: Зависимость суммарного числа итераций линейного поиска от числа итераций ускоренного метода. Полный график (слева) и приближенный график (справа)

Среднее число итераций для простого метода: 2.012

Среднее число итераций для ускоренного метода: 4.026

Выводы: Видим, что среднее число итераций линейного поиска действительно примерно равно 2. В случае же ускоренного метода получается примерно 4^1 .







Эксперимент 3: Сравнение методов

Генерируем данные:

- Матрица A размера $m \times n$ с помощью функции `np.random.rand` т.е. каждый элемент матрицы случайным образом выбран из нормального распределения на $[0, 1)$.
- b — нулевой вектор $\in \mathbb{R}^m$
- $x_0 \in \mathbb{R}^n$ также создается с помощью `np.random.rand`.

¹???







Зависимость от n



Выводы:

Видим, что ускоренный проксимальный метод работает лучше всего при любом n . По времени два других метода заканчивают раньше (это всего лишь показывает что одна итерация выполняется быстрее), но достигают гораздо меньшей точности. За одно и то же время ускоренный проксимальный метод может больше. Увеличение n влияет на его скорость сходимости меньше чем на остальные методы.

Зависимость от m













Выводы:

Для ускоренного проксимального метода видим зависимость от m аналогичную зависимости от n . Это объясняется тем, что сложность по m, n определяется сложностью матрично-векторного умножения, т.е. $O(mn)$

На проксимальный градиентный метод зависит от m сильнее чем от n . При увеличении m за одно и то же количество итераций он достигает меньшей точности.

Зависимость от λ





Выводы:

Увеличение λ ведет к отбору признаков (занулению части координат). Если λ то многие признаки быстро становятся нулями, а т.к. наш минимум в центре координат, мы получаем резкий спуск метода.